Université Paris-Est Créteil (UPEC)
Département de Mathématiques

Introduction à l'Économétrie
La Régression Linéaire Simple

Projet d'étude et de recherche

Étudiants
Amine El Mir
Khalil Benaissa
Dylan Au Yeung

Encadrante : **Sophie Laruelle**

Référence bibliographique principale

Gilbert Saporta, *Probabilités, analyse des données et Statistique*, Éditions TECHNIP, 2006, Chapitre 16.

Abstract

Econometrics is the discipline that uses statistical methods to test and quantify economic theories from empirical observations. This report is dedicated to the study of simple linear regression, the most fundamental econometric model, in which a response variable Y is modelled as a linear function of a single explanatory variable X up to a random noise term ε. We first present the theoretical regression model, distinguishing the probabilistic setting (regression between random variables) from the fixed-design setting (linear model). We then derive the Ordinary Least Squares (OLS) estimators a and b of the intercept α and slope β, show that the regression line passes through the empirical centre of gravity, and establish, via three classical theorems, that these estimators are unbiased (Theorem 1), of minimum variance among all linear unbiased estimators (Gauss–Markov theorem, Theorem 2), and that the residual variance estimator $\hat{\sigma}^2$ is also unbiased (Theorem 3). Statistical tests (analysis of variance, Student test) and a numerical illustration on a real dataset are also presented.

0 Table des matières

1 Introduction **2**

2 Le Modèle Théorique de la Régression Linéaire Simple **2**
2.1 Le cas probabiliste : régression entre variables aléatoires 2
2.2 Le modèle linéaire à régresseurs fixes 3

3 Estimation par la Méthode des Moindres Carrés **3**
3.1 Principe et critère de minimisation 4
3.2 Calcul des estimateurs 4

4 Propriétés des Estimateurs MCO **5**
4.1 Théorème 1 (Sans biais) 5
4.2 Variances des estimateurs 6
4.3 Optimalité : le théorème de Gauss-Markov (Théorème 2) 6

5 Estimation de la Variance des Erreurs **7**

6 Tests Statistiques dans le Modèle Linéaire **8**
6.1 Analyse de variance de la régression 8
6.2 Test de Student sur β 8

7 Illustration Numérique **9**
7.1 Modèle d'Evaluation des Actifs Financiers appliquée à LVMH 9
7.2 Loi de Keynes sur données de l'INSEE 10

8 Conclusion **10**

1 Introduction

L'économétrie est une branche des statistiques appliquées dont l'objet est de mettre à l'épreuve des théories économiques en ajustant des modèles mathématiques à des observations. L'exemple emblématique, qui guidera tout ce rapport, est la loi de Keynes : la consommation Y d'un ménage est supposée être une fonction linéaire de son revenu X. On cherche à tester cette hypothèse et à estimer les paramètres du modèle sur des données réelles.

Le modèle de régression linéaire simple est le modèle économétrique le plus élémentaire. Il suppose que l'espérance conditionnelle de Y sachant X est une fonction affine de X :

$$\mathbb{E}(Y \mid X) = \alpha + \beta X.$$

L'objectif est d'estimer les paramètres α (ordonnée à l'origine) et β (pente, ou propension marginale à consommer) à partir d'un échantillon $(x_i, y_i)_{i=1}^n$, ainsi que la variance σ^2 du terme d'erreur.

Ce rapport est organisé comme suit. La section 2 présente le modèle théorique selon les deux angles classiques : le cas probabiliste (régression entre variables aléatoires) et le modèle linéaire à régresseurs fixes. La section 3 dérive les estimateurs des moindres carrés a et b. La section 4 établit leurs propriétés fondamentales via les trois théorèmes fondamentaux que nous établirons dans ce rapport. La section 6 aborde les tests statistiques associés. Enfin, la section 7 illustre la méthode sur un exemple numérique, avec une implémentation Python.

2 Le Modèle Théorique de la Régression Linéaire Simple

Dans cette section, nous posons le cadre théorique de la régression linéaire simple et les hypothèses probabilistes sur lesquelles repose la méthode.

2.1 Le cas probabiliste : régression entre variables aléatoires

Soient X et Y deux variables aléatoires réelles de carré intégrable. On sait que l'espérance conditionnelle $\mathbb{E}(Y \mid X)$ est la meilleure approximation de Y par une fonction de X au sens de l'erreur quadratique moyenne, et que le rapport de corrélation

$$\eta^2_{Y/X} = \frac{\mathrm{Var}(\mathbb{E}(Y \mid X))}{\mathrm{Var}(Y)}$$

mesure la qualité de cette approximation.

Définition 2.1 (Régression linéaire simple)**.** On dit que Y admet une régression linéaire sur X si l'espérance conditionnelle de Y sachant X est une fonction affine de X :

$$\mathbb{E}(Y \mid X) = \alpha + \beta X, \tag{1}$$

où $\alpha, \beta \in \mathbb{R}$.

On peut alors écrire :

$$Y = \alpha + \beta X + \varepsilon, \tag{2}$$

où $\varepsilon = Y - \mathbb{E}(Y \mid X)$ est le résidu aléatoire, vérifiant $\mathbb{E}(\varepsilon) = 0$ et $\mathrm{Cov}(\varepsilon, X) = 0$. On montre aussi que :

$$\beta = \frac{\mathrm{Cov}(X,Y)}{\mathrm{Var}(X)} = \rho\frac{\sigma_Y}{\sigma_X}, \qquad \alpha = \mathbb{E}(Y) - \beta\,\mathbb{E}(X),$$

et que dans ce cas $\rho^2 = \eta^2_{Y/X}$, c'est-à-dire que le coefficient de corrélation linéaire capture entièrement la liaison entre X et Y.

2.2 Le modèle linéaire à régresseurs fixes

La méthode des moindres carrés s'applique également au cas où les x_i sont des valeurs fixées non aléatoires, par exemple des périodes d'observations. On parle alors de modèle linéaire plutôt que de régression.

Définition 2.2 (Modèle linéaire simple)**.** Pour n observations, le modèle linéaire simple s'écrit :

$$y_i = \alpha + \beta x_i + \varepsilon_i, \quad i = 1, \ldots, n, \tag{3}$$

où les x_i sont des constantes données, et les ε_i sont des réalisations indépendantes d'une variable d'espérance nulle et de variance constante σ^2.

Le bon usage de l'estimateur MCO repose sur un ensemble d'hypothèses portant sur les perturbations ε_i, que nous adoptons dans la suite en suivant la présentation du chapitre 4 du polycopié de cours [4] :

H1 $\forall i,\ \mathbb{E}[\varepsilon_i] = 0$: la perturbation est centrée.

H2 $\forall i,\ x_i$ est observé sans erreur (régresseurs fixes).

H3 $\forall i,\ \mathrm{Cov}(x_i, \varepsilon_i) = 0$: X et ε sont linéairement indépendants.

H4 $\forall i,\ \mathrm{Var}(\varepsilon_i) = \sigma^2$: homoscédasticité des perturbations.

H5 $\forall i \neq j,\ \mathrm{Cov}(\varepsilon_i, \varepsilon_j) = 0$: les perturbations sont non corrélées.

H6 $\forall i,\ \varepsilon_i \sim \mathcal{N}(0, \sigma^2)$: normalité des perturbations (nécessaire pour les tests exacts).

Remarque 2.3. Les hypothèses H1 à H5 suffisent pour établir le sans-biais et le théorème de Gauss-Markov. L'hypothèse H6 est requise en plus pour construire des tests statistiques exacts à partir des lois de Student et de Fisher. Les propriétés de la méthode des moindres carrés ne dépendent que des lois conditionnelles à X fixé. On prendra garde de parler de corrélation entre Y et X que lorsque X est aléatoire.

3 Estimation par la Méthode des Moindres Carrés

Cette section est dédiée à la construction des estimateurs MCO de α et β par minimisation de la somme des carrés des résidus, selon la méthode de Gauss.

3.1 Principe et critère de minimisation

On dispose de n couples (x_i, y_i). La méthode des moindres carrés reprend sur l'échantillon la propriété que $\mathbb{E}(Y \mid X) = \alpha + \beta X$ est la meilleure approximation de Y par X en moyenne quadratique. On cherche donc à ajuster au nuage de points (x_i, y_i) une droite $y^* = a + bx$ de telle sorte que

$$\sum_{i=1}^{n}(y_i - y_i^*)^2 = \sum_{i=1}^{n}(y_i - a - bx_i)^2 = F(a,b)$$

soit minimal.

3.2 Calcul des estimateurs

Proposition 3.1 (Estimateurs MCO)**.** *Le minimum de $F(a,b)$ est atteint pour les valeurs a et b solutions du système des équations normales :*

$$\frac{\partial F}{\partial a} = 0 \quad et \quad \frac{\partial F}{\partial b} = 0,$$

ce qui donne :

$$\sum_{i=1}^{n}(y_i - a - bx_i) = 0 \quad \Longleftrightarrow \quad \bar{y} = a + b\bar{x}, \tag{4}$$

$$\sum_{i=1}^{n} x_i(y_i - a - bx_i) = 0. \tag{5}$$

La solution est :

$$b = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2} = r\frac{s_y}{s_x}, \qquad a = \bar{y} - b\bar{x}, \tag{6}$$

où r est le coefficient de corrélation linéaire empirique, s_x et s_y sont les écarts-types empiriques de X et Y.

Démonstration. On applique les hypothèses :

$$\frac{\partial F}{\partial a} = -2\sum_{i=1}^{n}(y_i - a - bx_i) = 0 \quad \Rightarrow \quad \sum_i y_i = na + b\sum_i x_i, \quad \text{soit} \quad \bar{y} = a + b\bar{x}.$$

$$\frac{\partial F}{\partial b} = -2\sum_{i=1}^{n} x_i(y_i - a - bx_i) = 0 \quad \Rightarrow \quad \sum_i x_i y_i = a\sum_i x_i + b\sum_i x_i^2.$$

Avec $a = \bar{y} - b\bar{x}$ dans la seconde équation on a :

$$\sum_i x_i y_i = (\bar{y} - b\bar{x})\sum_i x_i + b\sum_i x_i^2 \quad \Rightarrow \quad \sum_i x_i y_i - n\bar{x}\bar{y} = -b\bar{x}^2 n + b\sum_i x_i^2$$

$$\Rightarrow \quad \sum_i x_i y_i - n\bar{x}\bar{y} = b\left(\sum_i x_i^2 - n\bar{x}^2\right), \quad \text{ainsi} \quad \sum_i (x_i - \bar{x})(y_i - \bar{y}) = b\sum_i (x_i - \bar{x})^2,$$

d'où la formule (6). La fonction F est strictement convexe en (a, b) donc ce point critique est bien un minimum global. □

Remarque 3.2 (Propriété géométrique). L'équation (4) montre que la droite des moindres carrés passe par le centre de gravité du nuage $(\bar{x}, \bar{y})$. Qui s'écrit :

$$y^* = \bar{y} + b(x - \bar{x}).$$

4 Propriétés des Estimateurs MCO

Nous établissons dans cette section les trois théorèmes fondamentaux de l'estimation par moindres carrés ordinaires. On note A et B les variables aléatoires dont a et b sont les réalisations.

Notons d'abord que b s'écrit plus simplement :

$$b = \frac{\sum_{i=1}^n (x_i - \bar{x}) y_i}{\sum_{i=1}^n (x_i - \bar{x})^2}, \tag{7}$$

qui résulte du fait que $\sum_i (x_i - \bar{x}) = 0$.

4.1 Théorème 1 (Sans biais)

Théorème 4.1 (Sans biais)**.** *Sous le modèle* (3)*, a, b et $y^* = a + bx$ sont des estimations sans biais de α, β et de $\mathbb{E}(Y \mid X = x) = \alpha + \beta x$:*

$$\mathbb{E}(A) = \alpha, \qquad \mathbb{E}(B) = \beta, \qquad \mathbb{E}(Y^*) = \alpha + \beta x.$$

Démonstration. Nous montrons que $\mathbb{E}_{(x)}(B) = \beta$, où $\mathbb{E}_{(x)}$ désigne l'espérance conditionnelle sachant les x_i. D'après (7) et la linéarité de l'espérance :

$$\mathbb{E}_{(x)}(B) = \frac{\sum_{i=1}^n (x_i - \bar{x})\, \mathbb{E}_{(x)}(Y_i)}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})(\alpha + \beta x_i)}{\sum_{i=1}^n (x_i - \bar{x})^2}.$$

Or $\sum_i (x_i - \bar{x}) \cdot \alpha = \alpha \sum_i (x_i - \bar{x}) = 0$, donc :

$$\mathbb{E}_{(x)}(B) = \frac{\beta \sum_{i=1}^n (x_i - \bar{x}) x_i}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\beta \sum_{i=1}^n (x_i - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \beta.$$

L'égalité $\mathbb{E}(B) = \mathbb{E}(\mathbb{E}_{(x)}(B)) = \beta$ en découle. Comme $A = \bar{y} - BX$, on a :

$$\mathbb{E}_{(x)}(A) = \mathbb{E}_{(x)}(\bar{Y}) - \bar{x}\, \mathbb{E}_{(x)}(B) = (\alpha + \beta\bar{x}) - \bar{x}\beta = \alpha.$$

Donc $\mathbb{E}(A) = \alpha$, et $\mathbb{E}(Y^*) = \mathbb{E}(A) + \mathbb{E}(B) \cdot x = \alpha + \beta x$. □

Remarque 4.2. Le fait d'être sans biais n'est qu'une qualité mineure pour des estimateurs. Le théorème suivant établit une propriété d'optimalité bien plus forte.

4.2 Variances des estimateurs

Avant d'énoncer le théorème de Gauss-Markov, calculons les variances de A et B.

Proposition 4.3 (Variances de A et B)**.** *Sous le modèle* (3) *avec* $\mathrm{Var}(\varepsilon_i) = \sigma^2$ *et* $\mathrm{Cov}(\varepsilon_i, \varepsilon_j) = 0$ *pour* $i \neq j$ *:*

$$\mathrm{Var}(B) = \frac{\sigma^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2}, \tag{8}$$

$$\mathrm{Var}(A) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2} \right). \tag{9}$$

Démonstration. En notant $c_i = (x_i - \bar{x})/\sum_j (x_j - \bar{x})^2$, on a $B = \sum_i c_i Y_i$, donc par indépendance des ε_i :

$$\mathrm{Var}(B) = \sigma^2 \sum_{i=1}^{n} c_i^2 = \frac{\sigma^2 \sum_i (x_i - \bar{x})^2}{\left(\sum_i (x_i - \bar{x})^2\right)^2} = \frac{\sigma^2}{\sum_i (x_i - \bar{x})^2}.$$

Puis, comme $A = \bar{Y} - B\bar{x}$ et B, $\bar{Y}$ sont non corrélés :

$$\mathrm{Var}(A) = \mathrm{Var}(\bar{Y}) + \bar{x}^2 \mathrm{Var}(B) = \frac{\sigma^2}{n} + \frac{\sigma^2 \bar{x}^2}{\sum_i (x_i - \bar{x})^2}.$$

□

Remarque 4.4 (Covariance entre A et B). On montre de même que [4] :

$$\mathrm{Cov}(A, B) = -\bar{x}\,\mathrm{Var}(B) = \frac{-\bar{x}\,\sigma^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2}.$$

Ainsi, lorsque $\bar{x} > 0$, la pente et l'ordonnée à l'origine estimées sont corrélées négativement : si b augmente, a tend à diminuer (et réciproquement), ce qui traduit la contrainte que la droite passe par le centre de gravité $(\bar{x}, \bar{y})$.

4.3 Optimalité : le théorème de Gauss-Markov (Théorème 2)

Théorème 4.5 (Gauss-Markov)**.** *Sous le modèle* (3)*, parmi tous les estimateurs sans biais de* α *et* β *qui sont des fonctions linéaires des* Y_i*, les estimateurs MCO* A *et* B *sont ceux de variance minimale : ce sont les MSLB (Meilleurs estimateurs Sans biais Linéaires).*

Démonstration. Nous montrons le résultat pour B ; le cas de A est analogue. Soit $\widetilde{B} = \sum_i \ell_i Y_i$ un estimateur linéaire sans biais quelconque. La condition de sans-biais donne :

$$\mathbb{E}_{(x)}(\widetilde{B}) = \sum_i \ell_i(\alpha + \beta x_i) = \beta \quad \forall \alpha, \beta \quad \Longleftrightarrow \quad \sum_i \ell_i = 0 \quad \text{et} \quad \sum_i \ell_i x_i = 1.$$

Posons $d_i = \ell_i - c_i$ où $c_i = (x_i - \bar{x})/\sum_j (x_j - \bar{x})^2$. Les conditions de sans-biais deviennent $\sum_i d_i = 0$ et $\sum_i d_i x_i = 0$. On calcule :

$$\mathrm{Var}(\widetilde{B}) = \sigma^2 \sum_i (\ell_i)^2 = \sigma^2 \sum_i (c_i + d_i)^2 = \sigma^2 \left(\sum_i c_i^2 + 2 \sum_i c_i d_i + \sum_i d_i^2 \right).$$

Le terme croisé vaut :

$$\sum_i c_i d_i = \frac{\sum_i (x_i - \bar{x}) d_i}{\sum_j (x_j - \bar{x})^2} = \frac{\sum_i x_i d_i - \bar{x} \sum_i d_i}{\sum_j (x_j - \bar{x})^2} = 0$$

par les conditions de sans-biais. Donc :

$$\mathrm{Var}(\widetilde{B}) = \sigma^2 \sum_i c_i^2 + \sigma^2 \sum_i d_i^2 = \mathrm{Var}(B) + \sigma^2 \sum_i d_i^2 \geq \mathrm{Var}(B),$$

avec égalité si et seulement si $d_i = 0$ pour tout i, c'est-à-dire $\widetilde{B} = B$. □

5 Estimation de la Variance des Erreurs

Cette section présente la construction et le sans-biais de l'estimateur de σ^2.

Définition 5.1 (Résidus et variance résiduelle)**.** Les écarts résiduels sont $e_i = y_i - y_i^* = y_i - a - bx_i$. La variance résiduelle empirique est $s_{y/x}^2 = \frac{1}{n} \sum_{i=1}^n e_i^2$.

On établit d'abord deux propriétés des résidus.

Proposition 5.2 (Propriétés des résidus)**.** *Les résidus e_i vérifient : $\sum_{i=1}^n e_i = 0$ et $\sum_{i=1}^n x_i e_i = 0$.*

Démonstration. Ces deux identités sont exactement les équations normales (4)–(5), réécrites en termes des résidus $e_i = y_i - a - bx_i$. □

Remarque 5.3. La nullité de $\sum e_i$ montre que les résidus ne sont pas des réalisations indépendantes : ils sont soumis à deux contraintes linéaires.

Théorème 5.4 (Sans biais de $\hat{\sigma}^2$)**.** *L'estimateur*

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n e_i^2}{n-2} = \frac{n\, s_{y/x}^2}{n-2} \tag{10}$$

est un estimateur sans biais de σ^2 : $\mathbb{E}[\hat{\sigma}^2] = \sigma^2$.

Démonstration. Exprimons e_i en fonction des erreurs vraies ε_i :

$$e_i = y_i - a - bx_i = (\alpha + \beta x_i + \varepsilon_i) - (\bar{y} - b\bar{x}) - bx_i = \varepsilon_i - \bar{\varepsilon} - (b - \beta)(x_i - \bar{x}),$$

où $\bar{\varepsilon} = \frac{1}{n} \sum_i \varepsilon_i$. En élevant au carré et en sommant :

$$\sum_i e_i^2 = \sum_i \varepsilon_i^2 - n\bar{\varepsilon}^2 - (b - \beta)^2 \sum_i (x_i - \bar{x})^2.$$

En prenant l'espérance et en utilisant $\mathbb{E}[\bar{\varepsilon}^2] = \sigma^2/n$ et $\mathbb{E}[(b-\beta)^2] = \mathrm{Var}(B) = \sigma^2/\sum_i (x_i - \bar{x})^2$:

$$\mathbb{E}\left[\sum_i e_i^2\right] = n\sigma^2 - \sigma^2 - \sigma^2 = (n-2)\sigma^2.$$

Donc $\mathbb{E}[\hat{\sigma}^2] = \sigma^2$. □

Remarque 5.5. Le facteur $n-2$ traduit la perte de deux degrés de liberté consécutive à l'estimation de deux paramètres α et β.

6 Tests Statistiques dans le Modèle Linéaire

Sous l'hypothèse supplémentaire de normalité des erreurs, $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$, on dispose de tests exacts.

6.1 Analyse de variance de la régression

On dispose de la décomposition de la variance:

$$\underbrace{\sum_{i=1}^{n}(y_i - \bar{y})^2}_{\text{SCT (totale)}} = \underbrace{\sum_{i=1}^{n}(y_i^* - \bar{y})^2}_{\text{SCE (expliquée)}} + \underbrace{\sum_{i=1}^{n} e_i^2}_{\text{SCR (résiduelle)}} \quad . \tag{11}$$

Cette décomposition repose sur l'orthogonalité $\sum_i (y_i^* - \bar{y})(y_i - y_i^*) = 0$. On définit le coefficient de détermination $R^2 = \mathrm{SCE}/\mathrm{SCT} = r^2$.

Sous l'hypothèse $H_0 : \beta = 0$ (non-régression), on montre que [4] :

$$F = \frac{\mathrm{SCE}/1}{\mathrm{SCR}/(n-2)} = \frac{(n-2)\,R^2}{1-R^2} \sim \mathcal{F}(1;\, n-2).$$

La seconde expression, exprimée en fonction de R^2, montre directement que rejeter H_0 revient à tester si le coefficient de détermination est significativement non nul. Le tableau d'analyse de variance récapitule ces résultats :

Source	**SC**	**ddl**	**Carré moyen**
Régression	SCE	1	SCE
Résiduelle	SCR	$n-2$	$\mathrm{SCR}/(n-2)$
Totale	SCT	$n-1$	

6.2 Test de Student sur β

Un test équivalent consiste à tester $H_0 : \beta = 0$ contre $H_1 : \beta \neq 0$ via la statistique :

$$t = \frac{b}{\hat{\sigma}/\sqrt{\sum_i (x_i - \bar{x})^2}} \sim \mathcal{T}(n-2) \quad \text{sous } H_0.$$

Ce test est strictement équivalent au test F ci-dessus et au test $H_0 : \rho = 0$ sur le coefficient de corrélation [1].

7 Illustration Numérique

7.1 Modèle d'Evaluation des Actifs Financiers appliquée à LVMH

Le MEDAF est un modèle fondamental de la finance de marché, il établit que la prime de risque individuelle d'un actif, c'est à dire l'excès de rendement $E(R_i) - R_f$ par rapport au taux sans risque R_f est proportionnelle à la prime de risque du marché $E(R_m) - R_f$:

$$E(R_i) = R_f + \beta_i(E(R_m) - R_f) \tag{12}$$

le coefficient β_i mesure la sensibilité de l'actif aux fluctuations du marché. Le terme α_i est l'ordonnée à l'origine de la droite de régression, lorsque ce terme est strictement positif il indique un actif sous-évalué, si il est strictement négatif un actif surévalué et si il est nulle alors une valorisation juste. On peut alors montrer que

$$\beta_i = \rho_{i,m}\frac{\sigma_i}{\sigma_m} \tag{13}$$

où $\rho_{i,m}$ désigne le coefficient de corrélation entre l'actif et le marche, σ_i et σ_m sont leurs écart types respectifs on retrouve la formule de l'estimateur MCO.

Nous estimons ce modèle sur $n = 48$ rendements hebdomadaires de l'action LVMH et de l'indice CAC40, sur la période janvier 2024 – décembre 2024. Les rendements sont calculés à partir des prix de clôture P_t par :

$$r_t = \frac{P_t - P_{t-1}}{P_{t-1}}, \quad t = 1, \ldots, 51.$$

t	P_t^{LVMH} en euros	P_t^{CAC}	r_t^{LVMH} (en %)	r_t^{CAC} (en %)
0	669,90	7465,14	—	—
1	659,40	7371,64	−1,57	−1,25
2	773,10	7634,14	17,24	3,56
3	778,10	7592,26	0,65	−0,55
4	807,50	7647,52	3,78	0,73
5	815,80	7768,18	1,03	1,58

Les statistiques descriptives sur les $n = 48$ rendements sont :

$$\bar{x} = 0,0038\%, \quad \bar{y} = 0,0129\%, \quad s_x = 1,9622\%, \quad s_y = 4,8450\%, \quad r = 0,7436.$$

On en déduit les estimateurs MCO :

$$\hat{\beta} = r \cdot \frac{s_y}{s_x} = 0,7436 \times \frac{4,8450}{1,9622} = 1,8361, \qquad \hat{\alpha} = \bar{y} - \hat{\beta}\,\bar{x} = 0,0059\%.$$

Le coefficient de détermination vaut $R^2 = 0,5529$ et l'écart-type résiduel $\hat{\sigma} = 3,31\%$. On teste l'hypothèse nulle $H_0 : \beta = 0$ contre $H_1 : \beta \neq 0$. La statistique de Student donne :

$$t = \frac{\hat{\beta}}{\widehat{SE}(\hat{\beta})} = \frac{1,8361}{0,2434} = 7,54 > t^{(46)}_{97,5\%} = 2,01$$

avec une p-value de $1,41 \times 10^{-9}$: on rejette $H_0 : \beta = 0$ au seuil 5%. L'intervalle de confiance à 95% pour β est $[1,346\ ;\ 2,326]$.

Remarque 7.1. Le bêta estimé $\hat{\beta} = 1{,}84 > 1$ indique que LVMH est plus volatile que le marché sur cette période : une hausse de 1% du CAC40 est associée en moyenne à une hausse de $1,84\%$ de LVMH. Le $R^2 = 0{,}55$ signifie que le CAC40 explique 55% de la variabilité des rendements LVMH, le reste étant dû à des facteurs propres à l'entreprise. Enfin, $\hat{\alpha} \approx 0$ est cohérent avec l'hypothèse du MEDAF qui prédit $\alpha = 0$ pour un actif correctement valorisé.

7.2 Loi de Keynes sur données de l'INSEE

Pour illustrer d'avantage la méthode et faire le lien avec la problématique de l'introduction, nous appliquons la régression linéaire aux données de l'INSEE sur l'évolution des dépenses de consommation finale (Y) et du revenu brut (X) des ménages français entre 2010 et 2019 [4]. Les valeurs sont exprimées en pourcentage de variation par rapport à l'année précédente.

Année	**Consommation Y (%)**	**Revenu X (%)**
2010	3,0	2,8
2011	2,4	2,0
2012	0,9	1,0
2013	1,1	$-0,5$
2014	0,9	1,3
2015	1,7	1,1
2016	2,0	1,8
2017	2,3	2,6
2018	2,6	3,0
2019	2,5	3,1

Les statistiques descriptives donnent $n = 10$, $\bar{x} = 1{,}82$, $\bar{y} = 1{,}94$, $s_x^2 = 1{,}1476$, $s_y^2 = 0{,}5144$ et $s_{xy} = 0{,}6412$. Les estimateurs MCO sont :

$$\hat{b} = \frac{s_{xy}}{s_x^2} = \frac{0{,}6412}{1{,}1476} \approx 0{,}559 \qquad \hat{a} = \bar{y} - \hat{b}\,\bar{x} = 1{,}94 - 0{,}559 \times 1{,}82 \approx 0{,}923$$

Le coefficient de détermination vaut $R^2 \approx 0{,}697$, soit un coefficient de corrélation $r \approx 0{,}835$. Le test de Student donne $t \approx 4{,}28 > t_{0{,}975}^{(8)} = 2{,}306$ donc rejet de $H_0 : \beta = 0$ au seuil 5%.

Remarque 7.2. Ce résultat confirme la loi de Keynes évoquée en introduction : la consommation croît avec le revenu ($\hat{b} > 0$), mais avec une propension marginale à consommer inférieure à 1 ($\hat{b} \approx 0{,}56 < 1$). Le $R^2 = 0{,}70$ indique que le revenu explique environ 70% de la variabilité de la consommation sur cette période, ce qui est cohérent.

8 Conclusion

Nous avons étudié le modèle de régression linéaire simple $y_i = \alpha + \beta x_i + \varepsilon_i$ et ses propriétés fondamentales.

Les estimateurs MCO a et b s'obtiennent par minimisation de la somme des carrés des résidus ; la droite ajustée passe par le centre de gravité $(\bar{x}, \bar{y})$ du nuage et sa pente vaut $b = r\, s_y / s_x$. Les trois théorèmes centraux garantissent que :

- a, b et y^* sont **sans biais** (Théorème 1) ;
- A et B sont les **estimateurs de variance minimale** parmi tous les estimateurs linéaires sans biais — théorème de Gauss-Markov (Théorème 2) ;
- $\hat{\sigma}^2 = \sum e_i^2/(n-2)$ est un estimateur **sans biais** de σ^2 (Théorème 3), le dénominateur $n-2$ reflétant la perte de deux degrés de liberté.

Sous l'hypothèse de normalité des erreurs, la statistique de Student $t = b/\hat{\sigma}_b$ suit une loi $\mathcal{T}(n-2)$ sous $H_0 : \beta = 0$, ce test étant équivalent au test F d'analyse de variance et au test sur le coefficient de corrélation.

8 Références

[1] G. Saporta, *Probabilités, analyse des données et Statistique*, Éditions TECHNIP, Paris, 2006. Chapitre 16 : La régression simple, page 387–405.

[2] J. M. Wooldridge, *Introductory Econometrics: A Modern Approach*, 7e édition, Cengage Learning, 2019.

[3] G. Casella et R. L. Berger, *Statistical Inference*, 2e édition, Duxbury Press, 2002.

[4] S. Laruelle, *Introduction à l'Économétrie*, Polycopié de cours, Chapitre 4, Université Paris-Est Créteil (UPEC).